

# Квалитетот на пребарувањето наспроти квалитетот на генерирањето во RAG-системи за јазици со ограничени ресурси

Сандра Живановска

Димитар Димов

Соња Гиевска

Мартина Тошевска

Факултет за информатички науки и компјутерско инженерство  
Универзитет „Св. Кирил и Методиј“, Скопје, Северна Македонија

**Анстракт**—Генерирањето дополнето со пребарување (Retrieval-Augmented Generation, RAG) е широко применуван пристап за одговарање на прашања врз ограничена збирка документи. Кај јазиците со ограничени дигитални ресурси, вклучително и македонскиот, релативниот придонес на пребарувањето и генерирањето кон квалитетот на одговорот не е доволно утврден. Во оваа студија тој однос се испитува преку контролирана споредба на повеќе конфигурации за пребарување и две варијанти на генеративен модел.

Споредени се шест конфигурации за пребарување врз две споредливи збирки од Википедија: македонска збирка од 10.000 статии и 20.408 сегменти и англиска збирка од 10.000 статии и 51.109 сегменти. Сите конфигурации се оценети врз исти 300 прашања на македонски јазик, со непроменети генератор и системска инструкција; параметрите за повторно рангирање се еднакви во петте конфигурации што ја користат таа постапка. Влијанието на генераторот е проценето со повторно генерирање врз зачуваните контексти, со што пребарувањето е задржано непроменето.

Во испитаната поставеност, просечната разлика во token-F1 меѓу случаите во кои референтната статија е присутна, односно отсутна меѓу првите пет резултати, изнесува +0,2029 ( $n = 1.788$ ). Соодветната спарена разлика меѓу Gemini 2.5 Flash и Flash-Lite изнесува +0,0146 ( $n = 1.800$ ), што претставува однос од приближно 13,9 : 1. Просечната верност изнесува 0,921 при успешно и 0,400 при неуспешно пребарување. MK-BM25 постигнува hit@5 на ниво на документ од 0,523, а MK-Dense 0,983. Разликата меѓу MK-Dense и Translate-Retrieve не е статистички значајна ( $p = 0,57$ ). Наодите укажуваат дека, во рамките на испитаните модели и корпуси, успешноста на пребарувањето е посилно поврзана со квалитетот на одговорот од изборот меѓу двата генератори.

**Клучни зборови**—RAG, информациско пребарување, јазици со ограничени ресурси, македонски јазик, густо векторско пребарување, BM25, мултијазични векторски претставувања, RAGAS, меѓујазично пребарување

## I. Вовед

Системите RAG опфаќаат две последователни компоненти: пребарување релевантни текстуални сегменти и генерирање одговор врз основа на пронајдениот контекст. Грешките во која било од компонентите можат да го намалат крајниот квалитет, но бараат различни технички интервенции. Поради тоа, нивниот одделен придонес треба да се процени експериментално.

Перформансите утврдени за јазици со обемни дигитални ресурси не можат без проверка да се пренесат врз македонскиот јазик. Помалиот обем на достапните корпуси и

морфолошките особености можат да влијаат врз лексичкото и векторското пребарување. Затоа, ова истражување ја оценува улогата на пребарувањето во контролирана поставеност за македонски јазик.

Работната хипотеза е дека, во RAG-систем за јазик со ограничени ресурси, варијацијата во квалитетот на пребарувањето е посилно поврзана со квалитетот на одговорот отколку изборот меѓу споредуваните генератори. Хипотезата предвидува повисока верност и релевантност кога релевантната содржина е вклучена во контекстот, без оглед на употребениот генератор.

Истражувањето е организирано околу три прашања:

- ИП1. Која стратегија обезбедува највисок краен квалитет на одговорот на македонски јазик: еднојазично лексичко пребарување (BM25), еднојазично густо векторско пребарување, хибридно пребарување, меѓујазично пребарување во англиската збирка или двојазична фузија?
- ИП2. Колкав е релативниот придонес на пребарувањето и генерирањето кон набљудуваниот квалитет, и дали подобриот од двата испитани генератори го намалува ефектот од неуспешното пребарување?
- ИП3. Дали пребарувањето во англиска збирка со висок обем на ресурси го подобрува одговарањето на македонски прашања чии референтни одговори потекнуваат од македонската Википедија?

Придонесот на истражувањето се состои во контролирана споредба на шест конфигурации врз македонска и англиска збирка изедначени по бројот и видот на изворните статии; одделна процена на пребарувањето и генераторот со повторна употреба на идентични контексти; и објавување репродуцибилни резултати за македонски јазик, придружени со ограничувањата на автоматски создадената референтна збирка.

## II. Сродни истражувања

### A. Генерирање дополнето со пребарување

Lewis и соработниците [1] формализираа пристап во кој параметарското знаење на јазичниот модел се дополнува со непараметарска надворешна меморија. Нивните резултати покажаа подобрување на точноста и проверливоста во однос на чисто генеративни основни модели.

Подоцнежните истражувања ги опфатија сегментирањето на документите, изборот на модел за векторски претставувања, повторното рангирање и составувањето на влезната инструкција.

### Б. Лексичко наспроти густо векторско пребарување

BM25 [2] е веројатносен модел за лексичко рангирање заснован врз честотата на поимите и нивната распределба во документите. Неговата зависност од лексичко преклопување може да ја намали успешноста кога прашањето и релевантниот документ користат различни флексивни форми или парафрази.

Густото векторско пребарување [3] ги претставува прашањата и пасусите во заеднички векторски простор, при што рангирањето се заснова врз нивната семантичка блискост. Мултијазичните модели LaBSE [4], XLM-R [5] и BGE-M3 [6] овозможуваат примена и кај јазици за кои нема наменски модели. BGE-M3 поддржува густо, ретко и повеќевекторско претставување и е избран како заеднички модел за векторизација во сите релевантни конфигурации.

### В. Меѓујазично пребарување


Класичниот пристап кон меѓујазичното пребарување го преведува прашањето на јазикот на збирката [7], додека поновите пристапи користат заеднички векторски простор без експлицитен превод. Во истражувањето се вклучени двете постапки. XOR QA [8] и MIRACL [9] покажуваат дека успешноста на мултијазичното пребарување зависи од јазикот и збирката. Chirkova и соработниците [10] дополнително укажуваат дека намалувањето на квалитетот во мултијазични RAG-системи може да произлегува и од користењето контекст на друг јазик. Оваа студија испитува дали таков образец се појавува и за македонскиот јазик.

### Г. Оценување на RAG-системи

Лексичките мерки exact match и token-F1 имаат ограничена чувствителност кон семантички еквивалентни, но различно формулирани одговори. RAGAS [11] користи јазичен модел за процена на верноста, релевантноста на одговорот, прецизноста и одзивот на контекстот и точноста на одговорот. Оценувањето со јазичен модел, сепак, може да внесе систематска пристрасност, особено кога генераторот и оценувачот припаѓаат на исто семејство модели. Овој ризик е разгледан во Дел VII.

### Д. Македонскиот и другите словенски јазици

Македонскиот јазик има развиена глаголска флексија и постпозитивен определен член кај именските форми. Ваквата варијабилност може да го намали директното лексичко совпаѓање меѓу прашањата и документите. Истовремено, бројот на јавно достапни корпуси и специјализирани модели е помал отколку за англискиот јазик. Krsteski и соработниците [12] објавија отворен корпус и основен јазичен модел за македонски, што го зголемува опфатот на достапните ресурси, но не ја отстранува потребата од посебна емпириска проверка на пребарувањето.



Слика 1. Експериментален тек од подготовката на македонската и англиската збирка до оценувањето. Збирките се ограничени на по 10.000 статии. Корпусот LVSTCK е исклучен од конечната споредба.

## III. Податоци и методологија

Слика 1 го сумира експерименталниот тек од прибирањето на корпусите до пресметувањето на мерките. Постапката е поделена во девет фази. Фазите за пребарување и генерирање се прикажани одделно за да се означат двете групи променливи што се споредуваат во истражувањето.

### А. Корпуси

Во двете јазични збирки како извор е користена исклучиво Википедија. Македонскиот веб-корпус LVSTCK е изоставен бидејќи нема соодветна англиска збирка со споредлив начин на создавање. Неговото вклучување би довело разлика и во јазикот и во видот и обемот на изворните податоци.

Секоја збирка е ограничена на 10.000 статии, при што се задржани сите статии поврзани со референтните одговори. По сегментирањето се добиени 20.408 македонски и 51.109 англиски сегменти. Поголемиот број англиски сегменти произлегува од поголемата просечна должина на англиските статии и создава несиметрија во големината на множеството кандидати. Оваа несиметрија е наведена како ограничување во Дел VII.

## Б. Сегментирање и модели

Документите се поделени по реченици, со целна должина од приближно 384 токени и преклопување од 64 токени. За векторските претставувања е употребен BAAI/bge-m3, а за повторно рангирање BAAI/bge-reranker-v2-m3, повеќејазичен вкрстен енкодер од типот воведен од Nogueira и Cho [13].

Првата фаза на секоја конфигурација враќа 50 кандидати. Во петте конфигурации со повторно рангирање, вкрстениот енкодер ги оценува првите 20 кандидати и ги избира петте сегменти што го формираат контекстот. MK-BM25 не користи повторно рангирање, па контекстот се формира од првите пет резултати на BM25. Кај хибридна конфигурација тежината на густата и лексичката компонента е  $\alpha = 0,5$ , а параметрите на BM25 се  $k_1 = 1,5$  и  $b = 0,75$ . Во Translate-Retrieve, прашањето се преведува од македонски на англиски со Google Cloud Translation.

Ограничувањето на повторното рангирање на првите 20 кандидати е воведено поради достапните пресметковни ресурси и е применето идентично во сите пет конфигурации што го користат вкрстениот енкодер. За мерките  $\text{recall}@50$  и MRR е задржано целото првично рангирање од 50 кандидати.

## В. Конфигурации за пребарување

Табела I ги прикажува шесте испитувани конфигурации. Тие ги опфаќаат лексичкото, густото векторско и хибридното пребарување на македонски, два начина на пребарување во англиската збирка и фузија на резултатите од двете збирки.

## Г. Референтна збирка прашања

Оценувањето е изведено врз 300 прашања. Секој запис содржи прашање и референтен одговор на македонски јазик, како и идентификатори на релевантниот сегмент и изворната статија. Збирката е создадена автоматски со јазичен модел и не е рачно валидирана. Последиците од оваа постапка за валидноста на резултатите се разгледани во Дел VII.

## IV. Експериментална поставеност

### А. Генеративни модели и системска инструкција

Основниот генератор е Gemini 2.5 Flash, повикан преку Vertex AI. Gemini 2.5 Flash-Lite е употребен како втор генератор во одделната споредба на генеративните модели.

Температурата при генерирањето е поставена на 0,0. Системската инструкција бара одговор од една до две реченици на македонски јазик, заснован исклучиво врз дадениот контекст, и одговор „Не знам“ кога контекстот не е доволен. Ограничувањето на должината е воведено затоа што во прелиминарните извршувања се добиваа одговори од неколку стотини зборови, додека просечната должина на референтните одговори е приближно 29 зборови. Таа разлика непропорционално ја намалуваше вредноста на token-F1. Истата инструкција е применета во сите конфигурации.

За анализа на ИП2, Flash-Lite е применет врз контекстите зачувани при извршувањето со Flash, наместо повторно да се извршат пребарувањето и повторното рангирање. На тој начин, за секој пар прашање–конфигурација се менува само генеративниот модел.

## Б. Оценувач и мерки

Оценувањето со RAGAS е изведено со Gemini 2.5 Flash како оценувач и со text-embedding-004 како модел за векторски претставувања. Употребените мерки се поделени во три групи:

- **Мерки за квалитетот на одговорот, пресметани со RAGAS:** верност (faithfulness), релевантност на одговорот (answer relevancy), прецизност на контекстот (context precision), одзив на контекстот (context recall) и точност на одговорот (answer correctness).
- **Мерки за пребарувањето, пресметани без јазичен модел:**  $\text{hit}@5$ ,  $\text{hit}@10$ ,  $\text{recall}@50$  и MRR. Главните споредби се изведени на ниво на документ, односно според присуството и позицијата на релевантната статија во рангирањето.
- **Лексички мерки:** token-F1 и exact match, прикажани како дополнителни показатели.

Нивото на документ е избрано поради различната грануларност на референтните ознаки. За македонската збирка е означен конкретен релевантен сегмент, додека за англиската збирка се познати сите сегменти од соодветната статија, без попрецизно меѓујазично порамнување. Поради тоа, мерките на ниво на сегмент не се непосредно споредливи и можат да им дадат предност на англиските конфигурации. Мерката context\_coverage се пресметува од преклопувањето на нормализираните зборови во одговорот и контекстот; бидејќи контекстите се на различни јазици, таа не се користи за заклучоци меѓу македонските и англиските конфигурации.

## В. Статистичка постапка

Парните разлики меѓу конфигурациите се тествани со тестот на потпишани рангови на Wilcoxon и корекција по Holm–Bonferroni за 15 споредби. Анализата на верноста користи 140 целосни спарени набљудувања, а анализата на пребарувањето 294, бидејќи шест прашања немаат англиски соодветник. Разликата во token-F1 меѓу успешно и неуспешно пребарување е проценета со U-тестот на Mann–Whitney врз 1.788 оценливи набљудувања прашање–конфигурација. Разликата меѓу генераторите е тестирана со парен тест на Wilcoxon врз 1.800 парови. Зависноста меѓу повеќекратните набљудувања за исто прашање не е моделирана и е наведена како ограничување во Дел VII.

## V. Резултати

Експериментот е изведен на 29 август 2026 година и опфаќа шест конфигурации по 300 прашања. Одговорите се генерирани со Gemini 2.5 Flash. За секоја конфигурација

Табела I  
Испитувани конфигурации за пребарување.

| Ознака              | Име                 | Пребарување              | Корпус   | Забелешка                                                 |
|---------------------|---------------------|--------------------------|----------|-----------------------------------------------------------|
| mk_bm25             | MK-BM25             | лексичко (BM25)          | MK       | без повторно рангирање                                    |
| mk_dense            | MK-Dense            | густо векторско (BGE-M3) | MK       | —                                                         |
| mk_hybrid           | MK-Hybrid           | густо векторско + BM25   | MK       | $\alpha = 0,5$                                            |
| translate_retrieve  | Translate-Retrieve  | густо векторско          | АНГ      | македонското прашање е преведено на англиски              |
| cross_lingual_embed | Cross-lingual Embed | густо векторско          | АНГ      | македонското прашање е векторизирано директно             |
| bilingual_fusion    | Bilingual Fusion    | фузија на резултати      | MK + АНГ | пребарување во двата корпуса, фузија и повторно рангирање |

биле избрани 150 прашања за RAGAS-оценување; по вклучувањето на нецелосните оценки, бројот на достапни вредности зависи од мерката.

#### А. Квалитет на одговорот

Табела II ги прикажува мерките за квалитетот на одговорот. Според описните вредности, MK-Dense, MK-Hybrid и Bilingual Fusion имаат највисоки резултати, по нив следуваат двете конфигурации со англиската збирка, а MK-BM25 има најниски вредности кај сите пет мерки.

Најизразено отстапување е забележано кај верноста на MK-BM25 (0,552). Кај останатите пет конфигурации вредностите се движат од 0,892 до 0,967. Бидејќи генераторот, системската инструкција и температурата се непроменети, овој образец е во согласност со претпоставката дека квалитетот на обезбедениот контекст е поврзан со верноста на одговорот.

#### Б. Квалитет на пребарувањето на ниво на документ

Табела III ги прикажува објективните мерки на пребарувањето на ниво на документ. За разлика од описните RAGAS-вредности во Табела II, конфигурациите што ја користат англиската збирка постигнуваат високи вредности за пронаоѓање на релевантната статија.

Bilingual Fusion и MK-Dense имаат највисоки вредности за  $\text{hit@5}$  и MRR. Translate-Retrieve постигнува  $\text{hit@5}$  од 0,969. MK-Hybrid има  $\text{recall@50}$  од 0,993, еднаков со MK-Dense, но понизок MRR од 0,746, што покажува дека релевантната статија често е присутна меѓу кандидатите, но е поставена пониско во рангирањето. Кај MK-BM25, релевантната статија се појавува меѓу првите пет резултати во 52,3% од случаите.

#### В. Лексички мерки

Табела IV ги прикажува лексичките мерки како дополнителни показатели.

Exact match има вредност 0 кај сите шест конфигурации. Оваа мерка бара целосна текстуална идентичност и затоа е несоодветна како единствен показател за слободно формулирани одговори. Token-F1 се движи од 0,162 кај MK-BM25 до 0,326 кај MK-Dense. Редоследот е сличен на оној кај RAGAS-мерките, но поради различната чувствителност на лексичките и семантичките мерки, token-F1 се толкува само како дополнителен показател.

#### Г. Пребарувањето наспроти генерирањето

За анализа на ИП2, резултатите прво се групирани според тоа дали референтната статија е присутна меѓу првите пет резултати, при непроменет генератор. Оваа поделба претставува описна споредба на успешно и неуспешно пребарување, а не случајно распределена интервенција.

Просечните вредности се повисоки во групата со успешно пребарување кај сите три прикажани мерки. Потоа двата контраста се изразени како разлики во token-F1. Повторната употреба на зачуваните контексти обезбедува спарена споредба на двата генератори при идентични резултати од пребарувањето.

Разликата во token-F1 меѓу успешно и неуспешно пребарување е 13,9 пати поголема од спарената разлика меѓу Flash и Flash-Lite. Овој однос ги опишува набљудуваните разлики во конкретната поставеност и не претставува универзална мерка на причински ефект.

Не е утврдена статистички значајна интеракција меѓу успешноста на пребарувањето и изборот на генератор. Разликата меѓу генераторите изнесува +0,0152 при успешно и +0,0081 при неуспешно пребарување ( $p = 0,24$ ). Според тоа, во опфатот на споредените модели нема доказ дека Flash ја надоместува отсутноста на релевантната статија подобро од Flash-Lite.

#### Д. Статистичка значајност

По корекцијата по Holm–Bonferroni, меѓу петте конфигурации различни од MK-BM25 не е утврдена статистички значајна парна разлика во верноста ( $n = 140$  целосни парови). Секоја од тие конфигурации има повисока верност од MK-BM25, со просечни разлики од 0,343 до 0,424 и коригирани  $p$ -вредности не поголеми од  $2,75 \times 10^{-8}$ .


Кај  $\text{hit@5}$  на ниво на документ, разликата меѓу MK-Dense (0,983) и Translate-Retrieve (0,969) не е статистички значајна (коригирано  $p = 0,57$ ), ниту разликата меѓу Bilingual Fusion (0,987) и MK-Dense (коригирано  $p = 0,66$ ). Cross-lingual Embed е статистички послаб од MK-Dense, Translate-Retrieve и Bilingual Fusion, но не и од MK-Hybrid.

Резултатите се во согласност со заситување на врската меѓу пребарувањето и верноста: големата разлика меѓу MK-BM25 и останатите конфигурации се одразува и врз квалитетот на одговорот, додека помалите разлики меѓу

Табела II

Квалитет на одговорот според RAGAS со генератор Gemini 2.5 Flash ( $n = 127-150$ , зависно од конфигурацијата и мерката). Највисоката вредност во секоја колона е задебелена.

| Конфигурација             | Faithfulness | Answer relevancy | Context precision | Context recall | Answer correctness |
|---------------------------|--------------|------------------|-------------------|----------------|--------------------|
| MK-Dense                  | <b>0,967</b> | <b>0,629</b>     | <b>0,860</b>      | <b>0,814</b>   | 0,414              |
| Bilingual Fusion          | 0,956        | 0,620            | 0,820             | 0,734          | 0,408              |
| MK-Hybrid                 | 0,932        | 0,608            | 0,832             | 0,800          | <b>0,416</b>       |
| Translate-Retrieve (АНГ)  | 0,905        | 0,510            | 0,627             | 0,472          | 0,359              |
| Cross-lingual Embed (АНГ) | 0,892        | 0,491            | 0,593             | 0,428          | 0,362              |
| MK-BM25                   | 0,552        | 0,298            | 0,347             | 0,309          | 0,276              |



Слика 2. Hit@5 на ниво на документ и верност според конфигурацијата, прикажани на скала од 0 до 1. MK-BM25 има најниски вредности кај двете мерки.

Табела III

Квалитет на пребарувањето на ниво на документ. За македонските конфигурации и двојазичната фузија  $n = 300$ ; за конфигурациите со англискиот индекс  $n = 294$ .

| Конфигурација             | hit@5        | MRR          | recall@50    |
|---------------------------|--------------|--------------|--------------|
| Bilingual Fusion          | <b>0,987</b> | <b>0,970</b> | 0,965        |
| MK-Dense                  | 0,983        | <b>0,970</b> | <b>0,993</b> |
| Translate-Retrieve (АНГ)  | 0,969        | 0,932        | 0,976        |
| MK-Hybrid                 | 0,903        | 0,746        | <b>0,993</b> |
| Cross-lingual Embed (АНГ) | 0,864        | 0,822        | 0,939        |
| MK-BM25                   | 0,523        | 0,458        | 0,687        |

Табела IV

Лексички мерки.

| Конфигурација             | Token-F1 | Exact match |
|---------------------------|----------|-------------|
| MK-Dense                  | 0,326    | 0,000       |
| MK-Hybrid                 | 0,325    | 0,000       |
| Bilingual Fusion          | 0,313    | 0,000       |
| Translate-Retrieve (АНГ)  | 0,240    | 0,000       |
| Cross-lingual Embed (АНГ) | 0,229    | 0,000       |
| MK-BM25                   | 0,162    | 0,000       |


петте поуспешни конфигурации не се статистички потврдени кај верноста.

#### Г. Воздржување од одговор при неуспешно пребарување


При отсуство на референтната статија меѓу првите пет резултати, генераторот дал точно формулиран одговор „Не знам.“ во 152 од 230 случаи (66,1%). Кога референтната

статија била присутна, истиот одговор се појавил во 35 од 1.558 случаи (2,2%).

Ова однесување делумно ја објаснува просечната верност од 0,400 во групата со неуспешно пребарување. Одговорот со кој моделот се воздржува од неподдржано тврдење е усогласен со контекст што не ја содржи бараната информација и затоа може да добие повисока оценка за верност од непоткрепен содржински одговор.



Слика 3. Просечни разлики во token-F1 поврзани со успешноста на пребарувањето и со изборот на генератор. Генераторите се споредени врз идентични зачувани контексти.



Слика 4. Однос меѓу hit@5 на ниво на документ и верноста за шесте конфигурации. Набљудуваното групирање на пет конфигурации е во согласност со заситување во опфатот на оваа референтна збирка.

Табела V

Квалитет на одговорот според присуството на референтната статија меѓу првите пет резултати, при непроменет генератор.

| Мерка            | Успешно пребарување | Неуспешно пребарување |
|------------------|---------------------|-----------------------|
| Faithfulness     | 0,921               | 0,400                 |
| Answer relevancy | 0,571               | 0,083                 |
| Token-F1         | 0,288               | 0,086                 |

Табела VI

Просечни разлики во token-F1 поврзани со успешноста на пребарувањето ( $n = 1.788$ ) и со изборот на генератор ( $n = 1.800$ ).

| Споредба                                           | Разлика | p                     |
|----------------------------------------------------|---------|-----------------------|
| Референтната статија е најдена наспроти непрајдена | +0,2029 | $1,3 \times 10^{-61}$ |
| Gemini 2.5 Flash наспроти Flash-Lite               | +0,0146 | $3,2 \times 10^{-4}$  |

## VI. Дискусија

### A. Однос меѓу пребарувањето и квалитетот на одговорот

Во однос на ИП2, просечната разлика во token-F1 меѓу успешно и неуспешно пребарување изнесува +0,2029

(Mann-Whitney  $U$ ,  $p = 1,3 \times 10^{-61}$ ), а спарената разлика меѓу Flash и Flash-Lite +0,0146 (Wilcoxon,  $p = 3,2 \times 10^{-4}$ ). Односот на овие описни разлики е приближно 13,9 : 1. Просечните вредности за верност и релевантност се исто така повисоки кога референтната статија е пронајдена (0,921 наспроти 0,400 и 0,571 наспроти 0,083).

Во испитаната поставеност, наодите даваат предност на интервенции во пребарувањето пред премин од Flash-Lite кон Flash. Заклучокот е ограничен на овие два генератори, употребените збирки и дадената системска инструкција; не е испитано дали истиот однос би се задржал со значително поголем модел.

#### *Б. Резултатот на BM25 во испитаната поставеност*

МК-BM25 постигнува hit@5 на ниво на документ од 0,523, наспроти 0,983 кај МК-Dense. Овој резултат е во согласност со две можни објаснувања: морфолошката варијабилност на македонскиот јазик и парафрастичката форма на дел од прашањата, кои го намалуваат лексичкото преклопување. Претходни истражувања утврдиле придобивки од морфолошка нормализација кај словенечкиот јазик [14] и кај повеќе европски јазици [15]. Сепак, оваа студија не спроведува аблација на морфолошката обработка, а МК-BM25, за разлика од другите пет конфигурации, не користи повторно рангирање. Затоа целата разлика не може причински да се припише само на лексичкиот модел.

Потребни се дополнителни експерименти со лематизација или стемирање, со и без повторно рангирање, за да се оддели придонесот на морфологијата од другите разлики во конфигурацијата. Проверка на истиот образец кај други словенски јазици би ја утврдила неговата преносливост.

#### *В. Резултати од пребарувањето преку англиската збирка*

Одговорот на ИПЗ бара одделно разгледување на мерките за пребарување и на мерките за квалитетот на одговорот. Translate-Retrieve и Cross-lingual Embed постигнуваат hit@5 на ниво на документ од 0,969 и 0,864. Нивните описни вредности за прецизност и одзив на контекстот се пониски и се движат од 0,593 до 0,627, односно од 0,428 до 0,472; кај МК-Dense тие изнесуваат 0,860 и 0,814.

Комбинацијата од висока успешност на ниво на статија и пониски содржински мерки укажува дека дел од ограничувањето може да настанува по пронаоѓањето на статијата: при изборот на конкретни сегменти или при генерирањето македонски одговор од англиски контекст. Поради различната грануларност на референтните ознаки, експериментот не овозможува овие два механизми целосно да се одделат. Слична чувствителност на јазикот на контекстот е забележана од Chirkova и соработниците [10].

Разликата во hit@5 меѓу МК-Dense и Translate-Retrieve не е статистички значајна (коригирано  $p = 0,57$ ), а парните разлики во верноста меѓу петте конфигурации различни од МК-BM25 не се значајни по корекцијата за повеќекратно тестирање. Оттука, резултатите не покажуваат мерлива предност од пребарувањето преку англиската збирка во

однос на директното густо векторско пребарување на македонски. Бидејќи трошокот и латентноста не се предмет на квантитативна анализа, заклучокот се однесува на квалитетот и архитектонската сложеност, а не на формална анализа на исплатливоста.

#### *Г. Резултати за двојазичната фузија*

Bilingual Fusion има највисока описна вредност за hit@5 (0,987), но разликата во однос на МК-Dense не е статистички значајна (коригирано  $p = 0,66$ ). Верноста е 0,956 кај Bilingual Fusion и 0,967 кај МК-Dense. Во оваа поставеност, додавањето на англиската збирка не обезбедува статистички потврдено подобрување во однос на МК-Dense. Овој наод не исклучува придобивка од фузија кога македонската збирка нема доволно содржина, бидејќи прашањата во студијата се создадени од македонски извори, а релевантните статии намерно се задржани во збирката.

#### *Д. Заситување во рамките на референтната збирка*

Отсуството на значајни разлики во верноста меѓу петте поуспешни конфигурации укажува дека, за употребените прашања, дополнителните подобрувања во hit@5 не се одразуваат мерливо врз оваа мерка за квалитетот на одговорот. Наодот не треба да се толкува како општа граница на придобивките од подобро пребарување.

Веројатно објаснување е ограничената тежина на референтната збирка: 65% од прашањата следат два повторливи обрасци, а 93% од референтните одговори се преземени дословно од изворниот сегмент. Високото лексичко преклопување ја намалува способноста на збирката да разликува добра од многу добра конфигурација за пребарување. Ова објаснување е хипотеза и бара проверка со рачно валидирана и лексички поразновидна збирка.

#### *Ѓ. Воздржување од одговор при недоволен контекст*

Одговорот „Не знам.“ се појавува во 66,1% од случаите со неуспешно и во 2,2% од случаите со успешно пребарување. Овој образец покажува дека системската инструкција често предизвикува воздржување од одговор кога релевантната статија не е присутна. За примена во домени со висок ризик, ваквото однесување би требало дополнително да се оцени со посебни мерки за точноста на воздржувањето и за неподдржаните тврдења. Просечната верност од 0,400 при неуспешно пребарување треба да се толкува во контекст на оваа стапка на воздржување: RAGAS може да оцени дека таквиот одговор е усогласен со контекстот, иако не дава содржински одговор на прашањето.

### **VII. Ограничувања**

Резултатите се толкуваат во рамките на следниве ограничувања.

- 1) **Автоматски создадена референтна збирка.** Сите 300 прашања и референтни одговори се создадени со јазичен модел и не се рачно валидирани. Дополнително, 65% од прашањата следат два повторливи

обрасци (28% во формата „...во дадениот извадок?“ и 37% во формата „Кој важен податок...“), а 93% од одговорите се дословно преземени од изворниот сегмент. Овие својства ја ограничуваат валидноста на апсолутните вредности и чувствителноста на споредбата.

- 2) **Оценувач од исто семејство модели.** Одговорите се генерирани со Gemini, а RAGAS-оценувањето е изведено со Gemini 2.5 Flash. Поради можната самопристрасност, резултатите треба да се проверат со оценувач од друго семејство модели или со човечки оценувачи.
- 3) **Несиметрична големина на множеството кандидати.** Македонската збирка содржи 20.408 сегменти, а англиската 51.109, иако двете имаат по 10.000 статии. Затоа разликите меѓу јазичните конфигурации не можат да се припишат исклучиво на јазикот.
- 4) **Различна грануларност на референтните ознаки.** За македонската страна е познат конкретниот релевантен сегмент, а за англиската страна само соодветната статија; сите нејзини сегменти се означени како релевантни. Поради тоа, мерките на ниво на сегмент можат да им дадат предност на англиските конфигурации и не се користат за главната меѓујазична споредба.
- 5) **Јазична зависност на context\_coverage.** Мерката го пресметува уделот на нормализирани зборови од одговорот што се појавуваат во контекстот. Таа не е споредлива кога македонски одговор се проверува еднаш врз македонски, а другпат врз англиски контекст, и затоа не се користи за меѓујазични заклучоци.
- 6) **Недостасувачки англиски соодветници.** Шест од 300 прашања немаат англиски соодветник. Тие се исклучени од мерките за пребарување кај англиските конфигурации, па таму  $n = 294$ .
- 7) **Опсег и статистичка анализа на генераторите.** Споредени се два блиски модела од исто семејство, Gemini 2.5 Flash и Flash-Lite. Односот 13,9 : 1 не може да се генерализира на значително поголеми модели. Покрај тоа, анализата ги обединува шесте набљудувања за секое прашање без хиерархиски да ја моделира нивната зависност, па  $p$ -вредностите од обединетата анализа треба да се толкуваат претпазливо.
- 8) **Разлики во повторното рангирање.** Вкрстениот енкодер ги оценува првите 20 од 50 кандидати во пет конфигурации, додека МК-BM25 не користи повторно рангирање. Затоа споредбата на МК-BM25 со останатите конфигурации не го изолира ефектот на лексичко наспроти густо векторско пребарување. Ограничувањето на 20 кандидати е применето еднакво само во конфигурациите со повторно рангирање.
- 9) **Ограничена должина на одговорот.** Системската инструкција бара една до две реченици за да се намали несразмерот со референтните одговори од приближно 29 зборови. Ова ја подобрува споредливоста на token-F1, но може да ја ограничи содржинската полнота на одговорите.

лижно 29 зборови. Ова ја подобрува споредливоста на token-F1, но може да ја ограничи содржинската полнота на одговорите.

- 10) **Опсег на студијата.** Истражувањето опфаќа еден јазик со ограничени ресурси, Википедија како единствен извор, збирки од по 10.000 статии и еден модел за векторски претставувања. Наодите не треба непосредно да се генерализираат надвор од оваа поставеност.

## VIII. Заклучок и идна работа

Во студијата е испитан односот меѓу пребарувањето и генерирањето во RAG-систем за македонски јазик. Во употребената поставеност, успешното пронаоѓање на референтната статија е поврзано со значително поголема разлика во token-F1 од разликата меѓу Gemini 2.5 Flash и Flash-Lite. Не е утврден доказ дека Flash ја надоместува неуспешноста на пребарувањето во поголема мера од Flash-Lite.

За ИП1, МК-Dense постигнува една од највисоките вредности кај мерките за пребарување и највисоки описни вредности за верност и релевантност, додека МК-BM25 има значително пониски резултати. За ИП2, описната разлика поврзана со успешноста на пребарувањето е приближно 13,9 пати поголема од спарената разлика меѓу двата генератори. За ИП3, Translate-Retrieve постигнува висока успешност на ниво на документ, но не е утврдена статистички мерлива предност во однос на МК-Dense.

За системи со услови слични на испитаните, резултатите ја поддржуваат употребата на мултијазично густо векторско пребарување пред воведување дополнителна меѓујазична патека. Оваа препорака се однесува на квалитетот на одговорите; студијата не содржи квантитативна анализа на трошокот или латентноста.

Понатамошната работа треба да вклучи рачно валидирана збирка со поголема лексичка разновидност, независен оценувач надвор од семејството Gemini и поширок опсег на генеративни и векторски модели. Одделна аблација на лематизацијата и повторното рангирање би овозможила попрецизно толкување на резултатот на BM25. Повторување на експериментот со споредлив веб-текст на двата јазика и со други словенски јазици би ја проверило преносливоста на наодите. Статистички модел со случајни ефекти за прашањето би ја земал предвид зависноста меѓу повеќекратните набљудувања.

## Литература

- [1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-augmented generation for knowledge-intensive NLP tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474. [Online]. Available: <https://papers.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- [2] S. Robertson and H. Zaragoza, “The probabilistic relevance framework: BM25 and beyond,” *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009. doi: <https://doi.org/10.1561/15000000019>.



- [3] V. Karpukhin, B. Oğuz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W. Yih, “Dense passage retrieval for open-domain question answering,” in *Proc. EMNLP*, 2020, pp. 6769–6781. doi: <https://doi.org/10.18653/v1/2020.emnlp-main.550>.
- [4] F. Feng, Y. Yang, D. Cer, N. Arivazhagan, and W. Wang, “Language-agnostic BERT sentence embedding,” in *Proc. ACL*, 2022, pp. 878–891. doi: <https://doi.org/10.18653/v1/2022.acl-long.62>.
- [5] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, “Unsupervised cross-lingual representation learning at scale,” in *Proc. ACL*, 2020, pp. 8440–8451. doi: <https://doi.org/10.18653/v1/2020.acl-main.747>.
- [6] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, “M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation,” in *Findings of ACL*, 2024, pp. 2318–2335. doi: <https://doi.org/10.18653/v1/2024.findings-acl.137>.
- [7] J.-Y. Nie, *Cross-Language Information Retrieval*, ser. Synthesis Lectures on Human Language Technologies, vol. 8. Morgan & Claypool, 2010. doi: <https://doi.org/10.2200/S00266ED1V01Y201005HLT008>.
- [8] A. Asai, J. Kasai, J. H. Clark, K. Lee, E. Choi, and H. Hajishirzi, “XOR QA: Cross-lingual open-retrieval question answering,” in *Proc. NAACL-HLT*, 2021, pp. 547–564. doi: <https://doi.org/10.18653/v1/2021.naacl-main.46>.
- [9] X. Zhang, N. Thakur, O. Ogundepo, E. Kamaloo, D. Alfonso-Hermelo, X. Li, Q. Liu, M. Rezagholizadeh, and J. Lin, “MIRACL: A multilingual retrieval dataset covering 18 diverse languages,” *Transactions of the ACL*, vol. 11, pp. 1114–1131, 2023. doi: [https://doi.org/10.1162/tacl\\_a\\_00595](https://doi.org/10.1162/tacl_a_00595).
- [10] N. Chirkova, D. Rau, H. Déjean, T. Formal, S. Clinchant, and V. Nikoulina, “Retrieval-augmented generation in multilingual settings,” in *Proc. 1st Workshop on Towards Knowledgeable Language Models*, 2024, pp. 177–188. doi: <https://doi.org/10.18653/v1/2024.knowllm-1.15>.
- [11] S. Es, J. James, L. Espinosa Anke, and S. Schockaert, “RAGAs: Automated evaluation of retrieval augmented generation,” in *Proc. EAACL System Demonstrations*, 2024, pp. 150–158. doi: <https://doi.org/10.18653/v1/2024.eacl-demo.16>.
- [12] S. Krsteski, B. Sazdov, M. Tashkovska, B. Gerazov, and H. Gjoreski, “Towards open foundation language model and corpus for Macedonian: A low-resource language,” in *Proc. 10th Workshop on Slavic Natural Language Processing*, 2025, pp. 44–57. doi: <https://doi.org/10.18653/v1/2025.bsnlp-1.6>.
- [13] R. Nogueira and K. Cho, “Passage re-ranking with BERT,” arXiv:1901.04085, 2019. [Online]. Available: <https://arxiv.org/abs/1901.04085>.
- [14] M. Popovič and P. Willett, “The effectiveness of stemming for natural-language access to Slovene textual data,” *Journal of the American Society for Information Science*, vol. 43, no. 5, pp. 384–390, 1992. doi: [https://doi.org/10.1002/\(SICI\)1097-4571\(199206\)43:5%3C384::AID-ASI6%3E3.0.CO;2-L](https://doi.org/10.1002/(SICI)1097-4571(199206)43:5%3C384::AID-ASI6%3E3.0.CO;2-L).
- [15] V. Hollink, J. Kamps, C. Monz, and M. de Rijke, “Monolingual document retrieval for European languages,” *Information Retrieval*, vol. 7, no. 1, pp. 33–52, 2004. doi: <https://doi.org/10.1023/B:INRT.0000009439.19151.4c>.